Práctica Final
Propuesta de Tema

Inteligencia Artificial en las Organizaciones
Grado Ingeniería Informática (2026/27)

Grupo 2:

Leon Jakub Wyrobek Smeder
José Barrio Bielsa
Hugo Pastrana Torres
Ismael Plaza Martín

Título	Segmentación de videojuegos de Steam mediante minería de datos y análisis de textos: relación de los grupos con la popularidad comercial y la valoración crítica.

Resumen

Este proyecto plantea identificar grupos de videojuegos de Steam con características similares mediante técnicas de aprendizaje no supervisado. Se construirá un dataset propio con información sobre géneros, categorías, precio, fecha de lanzamiento, descripciones y reseñas. Tras preparar las variables y aplicar técnicas de minería de textos, se utilizará K-Means u otro algoritmo de clustering para obtener e interpretar los grupos. La calidad del agrupamiento se evaluará mediante métricas internas y se analizará la relación de los grupos con los rangos estimados de propietarios de SteamSpy y las puntuaciones de Metacritic. Estos indicadores externos no se utilizarán para construir los grupos. Se espera obtener una segmentación interpretable y un análisis de su relación con la popularidad comercial y la valoración crítica.

Planteamiento técnico y viabilidad

a) **Datos y recursos.** Se construirá un dataset propio mediante un script en Python que obtenga las características de los videojuegos de Steam: precio original, géneros, categorías, descripción, fecha de lanzamiento y reseñas. Adicionalmente, se recopilarán los rangos estimados de propietarios de SteamSpy y las puntuaciones de la crítica de Metacritic, que se obtendrán del campo metacritic de la respuesta de appdetails de la API de la tienda de Steam. Este campo ofrece la puntuación tal como aparece en la ficha del juego, por lo que no es necesario un acceso adicional a Metacritic. Estos dos indicadores se reservarán exclusivamente para el análisis externo de los grupos y no se utilizarán como variables de entrada del clustering. Se incluirán únicamente juegos de pago, identificados por un precio original superior a cero, y con al menos 100 reseñas, delimitando así el alcance del estudio. Los datos se limpiarán y unificarán mediante el identificador de Steam y, cuando no exista un identificador compartido, mediante una correspondencia verificada entre títulos. Se registrará la fecha de extracción y se respetarán las condiciones de uso y los límites de peticiones de las fuentes. Los juegos sin puntuación de Metacritic podrán incluirse en el clustering, pero quedarán excluidos de las comparaciones que requieran esa puntuación. Los rangos de SteamSpy se tratarán como estimaciones de propietarios, no como cifras exactas de ventas.

b) **Técnicas de IA.** Minería de datos: se aplicará clustering para identificar grupos de videojuegos con características similares, utilizando variables como géneros, categorías, precio y antigüedad desde su lanzamiento. Se empleará K-Means como algoritmo inicial y se estudiará su comparación con otro método de agrupamiento. Las variables categóricas se codificarán y las numéricas se escalarán, ajustando el peso de los distintos bloques de características para evitar que alguno domine el agrupamiento.

   Text mining: se analizarán las descripciones y reseñas mediante TF-IDF. Para obtener una representación de dimensión fija por videojuego, se agregarán los vectores de sus reseñas calculando su media. La descripción se representará por separado y se incorporarán el porcentaje de reseñas positivas y la longitud media de las reseñas. Se estudiará la reducción de dimensionalidad de las representaciones textuales antes de combinarlas con las demás variables. No se incluirá el número total de reseñas, para evitar que el agrupamiento se base directamente en ese indicador de popularidad.

   Finalmente, se interpretarán los grupos mediante sus características y términos más representativos. Los rangos estimados de propietarios de SteamSpy y las puntuaciones de Metacritic no intervendrán en la construcción ni en la selección del agrupamiento, sino que se reservarán para analizar posteriormente su relación con la popularidad comercial y la valoración crítica.

c) **Desarrollo previsto.** En Python (pandas) se realizará la extracción, limpieza y unión de los datos, la aplicación de los filtros y la exportación a CSV. El modelado, la aplicación de técnicas de text mining (TF-IDF) y la comparación de las distintas configuraciones de clustering se desarrollarán también en Python, utilizando librerías como scikit-learn. Finalmente, se interpretarán los grupos y se analizarán sus diferencias utilizando los datos de SteamSpy y Metacritic, reservados exclusivamente para este análisis externo. El prototipo incluirá visualizaciones de los grupos y sus características.

d) **Evaluación.** Se evaluará la calidad del clustering mediante el coeficiente silhouette y el índice Davies-Bouldin, comparando distintos números de grupos y configuraciones. También se analizará la estabilidad del agrupamiento entre ejecuciones. Como análisis externo, se compararán las distribuciones de rangos estimados de propietarios de

SteamSpy y las puntuaciones de Metacritic entre los grupos, indicando la disponibilidad de estos datos en cada uno. Estos indicadores no se utilizarán para construir ni seleccionar el agrupamiento, sino para estudiar su relación con la popularidad comercial y la valoración crítica. Para garantizar la reproducibilidad, se entregará el repositorio de GitHub con el código fuente, el script de extracción y el dataset en CSV.

Índice preliminar de la memoria

1. Portada
2. Introducción y objetivos
3. Planteamiento y desarrollo (obtención del dataset, técnicas de IA y su justificación, implementación)
4. Resultados (métricas, gráficas y comparación entre el modelo A, sin reseñas, y el modelo B, con reseñas)
5. Análisis y discusión (interpretación, limitaciones como la no cobertura de juegos free-to-play, y posibles mejoras)
6. Conclusiones
7. Referencias
8. Anexos (opcional)

Bibliografía inicial

Revadike. *Get App Details*. En *InternalSteamWebAPI: Unofficial Steam Web API documentation* [wiki]. GitHub. github.com/Revadike/InternalSteamWebAPI/wiki/Get-App-Details

SteamSpy. SteamSpy API. steamspy.com/api.php [Documentación de la fuente de datos]

Birkett, J. (2018, 1 de mayo). Using Steam reviews to estimate sales. Grey Alien Games. greyaliengames.com/blog/using-steam-reviews-to-estimate-sales/ [Nota técnica de la industria] Game Developer (Gamasutra). (s. f.). Steam Spy and the specter of game sales transparency. gamedeveloper.com/business/steam-spy-and-the-specter-of-game-sales-transparency [Artículo de prensa especializada]

Lin, D., Bezemer, C.-P., Zou, Y. y Hassan, A. E. (2019). An empirical study of game reviews on the Steam platform. Empirical Software Engineering, 24, 170–207. [Artículo científico]